

Week5

☰ 연습과제

09 분류 실습 - 캐글 산탄데르 고객 만족 예측

산탄데르 고객 만족 예측 분석 개요

- 370개의 피처를 기반으로 고객 만족 여부 예측
- 피처 이름은 모두 익명 처리되어 속성 추정 불가
- 클래스 레이블 명: TARGET (1이면 불만 고객, 0이면 만족 고객)
- 모델 성능 평가: ROC-AUC(ROC 곡선 영역)로 평가 (불균형 데이터 세트에 적합)

데이터 전처리

데이터 로딩 및 확인

- 전체 데이터 세트 크기: (76020, 371)
- 피처 타입: float64(111개), int64(260개)로 모든 피처가 숫자 형
- Null 값 존재 여부: 없음
- 레이블 분포: 불만족 비율은 약 4% (0.04)로 대부분이 만족 데이터임

피처 가공 및 분리

- var3 칼럼: 예외 값으로 추정되는 -999999를 가장 값이 많은 2로 변환
- ID 피처: 단순 식별자이므로 드롭 처리
- 학습 데이터와 테스트 데이터 세트 분리: train_test_split 사용 (test_size=0.2)
- 학습/테스트 데이터 세트의 레이블 분포가 원본과 유사한지 확인

XGBoost 모델 학습과 하이퍼 파라미터 튜닝

기본 모델 학습

- XGBClassifier 및 사이킷런 래퍼 이용

- 주요 파라미터: `n_estimators=500`, `learning_rate=0.05`
- 조기 중단(early stopping) 설정: `early_stopping_rounds=100`, `eval_metric="auc"`
- 초기 성능 측정 결과: ROC AUC 약 0.8429

HyperOpt 기반 하이퍼 파라미터 튜닝

- 하이퍼 파라미터 검색 공간: `max_depth`, `min_child_weight`, `colsample_bytree`, `learning_rate`
- 목적 함수: 3-Fold 교차 검증을 통해 평균 ROC-AUC 값을 계산하여 반환 (-1을 곱해 최솟값 유도)
- 최적화 수행: `fmin()` 함수를 사용하여 50회 반복 수행
- 튜닝 후 결과: ROC AUC 약 0.8457로 개선

피처 중요도 시각화

- `plot_importance()` 메서드 이용
- 결과: `var38`과 `var15`가 예측 성능을 좌우하는 가장 중요한 피처로 나타남

LightGBM 모델 학습과 하이퍼 파라미터 튜닝

기본 모델 학습

- `LGBMClassifier` 이용
- 설정: `n_estimators=500`, `early_stopping_rounds=100`
- 초기 성능 측정 결과: ROC AUC 약 0.8384
- 특징: XGBoost보다 학습에 걸리는 시간이 단축됨

HyperOpt 기반 하이퍼 파라미터 튜닝

- 하이퍼 파라미터 검색 공간: `num_leaves`, `max_depth`, `min_child_samples`, `subsample`, `learning_rate`
- 목적 함수 구성: `LGBMClassifier` 객체 생성 및 3-Fold 교차 검증 수행
- 튜닝 후 결과: ROC AUC 약 0.8446으로 측정됨
- 활용 팁: 학습 시간이 빠르므로 추가적인 하이퍼 파라미터 적용 및 튜닝 시도 권장